



UNIVERSITÉ IBN ZOHR
ÉCOLE SUPÉRIEURE DE TECHNOLOGIE
DÉPARTEMENT INFORMATIQUE



RAPPORT DE PROJET DE STAGE

En vue de l'obtention du Diplôme Universitaire de Technologie (DUT)

Spécialité : Ingénierie des Données

Conception et Implémentation
d'un Pipeline Data Conteneurisé
avec Dash et Power BI

Réalisé par :
SAYKA Hassan

Sous la direction de :
Pr. Mohamed TIFROUT

Membres du Jury :

Pr. Mohamed TIFROUT EST Guelmim

Année Universitaire : 2025-2026

Dédicaces

À mes très chers parents,

*Aucun mot ne saurait exprimer l'ampleur de ma gratitude pour votre amour
inconditionnel, vos sacrifices continus et vos prières qui ont illuminé mon chemin.
Ce travail est le modeste fruit de votre soutien indéfectible et de la confiance que vous
m'avez toujours accordée.*

*Qu'il soit pour vous le témoignage de mon profond respect et de mon éternelle
reconnaissance.*

À ma famille, à mes frères et sœurs,

*Pour votre présence rassurante, vos encouragements constants et la force que vous
m'insufflez au quotidien.*

À mes amis et à mes camarades de promotion,

*Pour l'entraide, les échanges fructueux et les moments inoubliables partagés tout au
long de ce cursus.*

À tous ceux qui ont contribué, de près ou de loin, à l'aboutissement de ce projet.

Remerciements

Avant d’entamer la présentation de ce travail, je tiens à exprimer ma profonde gratitude et mes sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, à l’aboutissement de ce projet de fin d’études.

Mes premiers remerciements s’adressent à mon encadrante professionnelle, **Madame Ikram SAYKA**, au sein de la Direction Sécurité et Environnement d’OCP Jorf Lasfar. Je la remercie vivement pour m’avoir accueilli, encadré et soutenu tout au long de mon stage. Ses précieux conseils, sa disponibilité constante et son expertise métier ont été des éléments déterminants pour la réussite de ce projet.

Je tiens également à témoigner toute ma reconnaissance à mon encadrant pédagogique, **Professeur Mohamed TIFROUT**, pour son suivi rigoureux, ses orientations éclairées et la bienveillance avec laquelle il a dirigé mon travail. Ses directives m’ont permis de structurer ma démarche et de mener à bien cette mission.

J’adresse mes vifs remerciements aux membres du jury, qui m’ont fait l’honneur d’accepter d’examiner et d’évaluer ce travail.

Je remercie par ailleurs l’ensemble de l’équipe de la **Direction Sécurité et Environnement d’OCP Jorf Lasfar** pour leur accueil chaleureux, leur esprit de collaboration et le partage de leur savoir-faire, qui ont grandement facilité mon intégration et ma compréhension des enjeux du système SFE.

Enfin, je souhaite exprimer ma gratitude à l’ensemble du corps professoral et administratif de l’**École Supérieure de Technologie de Guelmim (ESTG)** pour la qualité de la formation dispensée et leur dévouement tout au long de mon cursus universitaire.

Résumé

Ce projet de fin d'études présente la conception et l'implémentation d'un pipeline de données automatisé (*ETL* — *Extract, Transform, Load*) dédié à la gestion et au suivi des actions du programme *Safety & Fire Excellence* (SFE) sur le site **JFC1** d'OCP Jorf Lasfar.

Le système développé ingère automatiquement des fichiers de données issus de plusieurs sources de sécurité industrielle (PSM, NH3, Haute Tension, Fire Fighting, Audits), les transforme en un modèle dimensionnel structuré (*Star Schema*) hébergé dans une base de données **MySQL 8.0**, et expose les données consolidées à un tableau de bord interactif **Power BI** pour le pilotage des indicateurs clés de performance (KPIs) de sécurité.

L'architecture technique repose sur **Python** (Pandas, SQLAlchemy, Pydantic) et est entièrement conteneurisée avec **Docker Compose**. Elle offre une double approche d'exécution : une interface web **Dash** permettant aux utilisateurs de déclencher le traitement manuellement, ainsi qu'un DAG **Apache Airflow** assurant l'orchestration quotidienne automatique du pipeline avec un système d'alerte en cas d'échec.

Les résultats démontrent une réduction significative du temps de consolidation des données SFE : de plusieurs heures de traitement manuel à quelques minutes d'intégration automatisée, avec une garantie de qualité des données, une traçabilité complète et une élimination rigoureuse des doublons par hachage SHA-256.

Mots-clés : ETL, Python, MySQL, Docker, Dash, Power BI, SQLAlchemy, Data Warehouse, SFE, OCP, Sécurité Industrielle, Apache Airflow.

Abstract

This graduation project presents the design and implementation of an automated data pipeline (*Extract, Transform, Load - ETL*) dedicated to managing and tracking action plans within the *Safety & Fire Excellence* (SFE) programme at OCP's **JFC1** site in Jorf Lasfar.

The developed system automatically ingests data files from various industrial safety sources (PSM, NH3, High Voltage, Fire Fighting, Audits), transforms them into a structured dimensional model (*Star Schema*) hosted in a **MySQL 8.0** database, and exposes the consolidated data to an interactive **Power BI** dashboard for monitoring safety key performance indicators (KPIs).

The technical architecture is built on **Python** (Pandas, SQLAlchemy, Pydantic) and is fully containerised using **Docker Compose**. It offers a dual execution approach : a **Dash** web interface allowing users to manually upload files and trigger the pipeline in a single click, alongside an **Apache Airflow** DAG that ensures daily automated orchestration with an alerting system in case of failure.

Results demonstrate a significant reduction in SFE data consolidation time : from several hours of manual processing to a few minutes of automated integration, while ensuring data quality, full traceability, and strict SHA-256-based deduplication.

Keywords : ETL, Python, MySQL, Docker, Dash, Power BI, SQLAlchemy, Data Warehouse, SFE, OCP, Industrial Safety, Apache Airflow.

Table des matières

Dédicaces	1
Remerciements	2
Résumé	3
Abstract	4
Liste des Figures	8
Liste des Tableaux	9
Liste des Abréviations	10
Introduction Générale	11
1 Contexte Général et Gestion de Projet	13
1.1 Introduction	13
1.2 Contexte du Projet	13
1.2.1 Le Groupe OCP : Un leader mondial engagé	13
1.2.2 Le Complexe Industriel de Jorf Lasfar : Un hub d'envergure internationale	14
1.2.3 La Direction HSE et le Programme SFE	14
1.3 Problématique	15
1.4 Objectifs du Projet	15
1.5 Cahier des Charges	16
1.5.1 Besoins Fonctionnels	16
1.5.2 Besoins Non Fonctionnels	16
1.6 Méthodologie de Travail : Approche Agile Scrum	17
1.6.1 Les Sprints	17
1.7 Planification du Projet (Diagramme de Gantt)	17
1.8 Outils de Travail et de Développement	18
1.9 Conclusion	18
2 État de l'Art et Écosystème Technologique	19

2.1	Introduction	19
2.2	Le Paradigme ETL en Data Engineering	19
2.2.1	Définition et Phases du Processus ETL	19
2.2.2	Modélisation en Étoile — Star Schema	20
2.2.3	SCD Type 2 — Suivi Historique des Modifications	20
2.3	Écosystème Python pour le Data Engineering	20
2.3.1	Python et la Bibliothèque Pandas	20
2.3.2	SQLAlchemy — ORM et Gestion de la Base de Données	20
2.3.3	Pydantic — Validation de la Configuration	21
2.4	Conteneurisation avec Docker	21
2.4.1	Architecture Multi-Stage	21
2.4.2	Docker Compose	21
2.5	Interface Web — Plotly Dash	21
2.6	Orchestration — Apache Airflow	22
2.7	Visualisation Décisionnelle — Microsoft Power BI	22
2.8	Conclusion	22
3	Conception et Modélisation du Système	23
3.1	Introduction	23
3.2	Architecture Globale du Système	23
3.3	Modélisation UML du Système	24
3.3.1	Diagramme des Cas d’Utilisation	24
3.3.2	Diagramme de Séquence	26
3.3.3	Diagramme de Déploiement	27
3.4	Conception de la Base de Données	28
3.4.1	Modèle Conceptuel des Données (MCD)	28
3.4.2	Dictionnaire de Données	28
3.5	Conclusion du chapitre	29
4	Implémentation et Réalisation Technique	30
4.1	Introduction	30
4.2	Implémentation de la Base de Données (Star Schema)	30
4.3	Développement des Scripts du Pipeline	31
4.3.1	Configuration et Validation — Pydantic Settings	32
4.3.2	Le Moteur ETL Principal (<code>etl_pipeline.py</code>)	32
4.3.3	Mécanisme de Déduplication SHA-256	33
4.4	L’Interface Utilisateur — Application Dash	33
4.5	Containerisation Docker	35

4.5.1	Le Dockerfile Multi-Stage	35
4.5.2	Docker Compose — Orchestration Multi-Services	36
4.6	Orchestration Apache Airflow	37
4.7	Résultats et Évaluation des Performances	39
4.8	Visualisation et Décisionnel avec Power BI	39
4.8.1	Dashboard 1 : KPIs Globaux et Taux de Réalisation	39
4.8.2	Dashboard 2 : Analyse par Entité OCP	40
4.8.3	Dashboard 3 : Analyse par Responsable	41
4.8.4	Dashboard 4 : Alertes Critiques P3 / P4	42
4.9	Conclusion du chapitre	43
	Conclusion Générale	44
	Bibliographie et Webographie	46
	Annexe Introduction aux Annexes	47
	Annexe A Schéma SQL et Règles Métier du Data Warehouse	48
	Annexe B Pipeline ETL : Validation de la Qualité des Données	50
	Annexe C Fichier de Configuration Docker Compose	51
	Annexe D Orchestration Automatisée (Apache Airflow)	53
	Annexe E Scripts Batch d'Accessibilité Utilisateur	55

Table des figures

1.1	Diagramme de Gantt — Planification du projet SFE ETL	18
3.1	Architecture technique globale du Pipeline SFE (Source, Interface, ETL, Data Warehouse et Présentation)	24
3.2	Diagramme des cas d'utilisation du système de gestion des actions SFE	25
3.3	Diagramme de séquence illustrant le traitement d'un fichier Excel SFE en bout en bout	26
3.4	Diagramme de déploiement des nœuds Docker et de l'outil BI	27
3.5	Modèle Conceptuel de la base de données MySQL — Star Schema SFE	28
4.1	Modélisation en étoile de la base de données <code>sfe_dwh</code>	31
4.2	Validation de la configuration au démarrage : classe <code>Settings</code> Pydantic et chargement du fichier <code>.env</code>	32
4.3	Exécution du pipeline ETL : traitement des fichiers Excel SFE et chargement dans MySQL	33
4.4	Mécanisme de déduplication par hachage SHA-256 : génération et vérification de l' <code>action_key</code>	33
4.5	Interface Dash de l'application SFE ETL : zone de téléversement et bouton de lancement du pipeline	34
4.6	Dockerfile multi-stage : stage Builder pour les dépendances et stage Runtime pour l'image finale allégée	35
4.7	Docker Compose : démarrage des services <code>mysql_db</code> et <code>etl_app</code> avec réseau <code>sfe_network</code>	36
4.8	DAG Apache Airflow <code>ocp_sfe_daily_etl</code> : vérification du dossier, exécution ETL et nettoyage des logs	38
4.9	Dashboard Power BI : KPIs globaux SFE — taux de réalisation, statuts et répartition par priorité	40
4.10	Dashboard Power BI : Analyse par entité OCP — taux de réalisation et nombre d'actions en retard par entité	41
4.11	Dashboard Power BI : Analyse par responsable — taux de réalisation et actions critiques par agent	42
4.12	Dashboard Power BI : Alertes critiques P3/P4 — actions en retard avec niveaux d'alerte (CRITIQUE/URGENT/ATTENTION)	43

Liste des tableaux

1.1	Sources de données SFE intégrées dans le pipeline	15
3.1	Dictionnaire de données de la table fact_actions	28
4.1	Tableau d'évaluation des performances du pipeline SFE ETL	39

Liste des Abréviations

API	Application Programming Interface
BI	Business Intelligence
CSV	Comma-Separated Values
DAG	Directed Acyclic Graph (Graphe Acyclique Dirigé)
DUT	Diplôme Universitaire de Technologie
DWH	Data Warehouse (Entrepôt de données)
ETL	Extract, Transform, Load
FF	Fire Fighting (Lutte contre l'incendie)
HT	Haute Tension
JFC1	Jorf Fertilizers Company 1
JSON	JavaScript Object Notation
KPI	Key Performance Indicator
MCD	Modèle Conceptuel des Données
NH3	Ammoniac (source de données SFE)
OCP	Office Chérifien des Phosphates
ORM	Object-Relational Mapping
PSM	Process Safety Management
SCD	Slowly Changing Dimension
SFE	Safety & Fire Excellence
SHA	Secure Hash Algorithm
SQL	Structured Query Language
UML	Unified Modeling Language
UUID	Universally Unique Identifier
YAML	YAML Ain't Markup Language

Introduction Générale

Dans le secteur de l'industrie chimique et des phosphates, la sécurité constitue un impératif stratégique de premier ordre. Au sein du complexe **OCP Jorf Lasfar**, le programme *Safety & Fire Excellence* (SFE) encadre l'ensemble des actions correctives et préventives issues d'audits, d'inspections et de diagnostics techniques réalisés sur les différents sites de production.

Le suivi de ces actions repose historiquement sur des fichiers Excel multi-feuilles, répartis entre plusieurs entités et compilés manuellement par les équipes HSE. Cette approche, bien qu'opérationnelle, génère des problèmes récurrents : données dupliquées, formats hétérogènes, impossibilité de consolider des indicateurs en temps réel, et absence d'historique traçable.

C'est dans ce contexte que s'inscrit notre Projet de Fin d'Études. Notre objectif principal est de concevoir et d'implémenter un **pipeline ETL** (*Extract, Transform, Load*) industriel, capable d'ingérer automatiquement les fichiers Excel SFE, de les transformer en un modèle dimensionnel structuré (Star Schema MySQL), et de restituer les données consolidées via une interface web et un tableau de bord Power BI accessible aux décideurs de l'entreprise.

Au-delà de la simple ingénierie des données, ce projet ambitionne de transformer les données brutes de sécurité en une véritable « intelligence décisionnelle » permettant d'anticiper les retards, d'identifier les zones à risque et d'améliorer le taux de réalisation des actions SFE.

Afin d'exposer clairement notre démarche, ce rapport est structuré en quatre chapitres principaux :

- Le **premier chapitre** plantera le décor en détaillant le contexte général du projet, la présentation d'OCP et du programme SFE, la problématique, les objectifs, le cahier des charges ainsi que la méthodologie Agile adoptée.
- Le **deuxième chapitre** sera consacré à l'état de l'art et à l'écosystème technologique. Nous y explorerons les concepts ETL, la modélisation en étoile (Star Schema), ainsi que les technologies retenues : Python, SQLAlchemy, Docker, Dash et Apache Airflow.
- Le **troisième chapitre** abordera la phase de conception et de modélisation. Nous

y présenterons l'architecture globale du pipeline, les diagrammes UML, ainsi que la structuration du Data Warehouse cible.

- Le **quatrième et dernier chapitre** constituera le cœur technique du projet. Il détaillera l'implémentation de chaque composant du système avant de s'achever par une évaluation des performances et la présentation de notre couche de Business Intelligence Power BI.

Chapitre 1

Contexte Général et Gestion de Projet

1.1 Introduction

L'ère de la transformation digitale industrielle impose aux entreprises de repenser leur rapport à la donnée. Dans le secteur de la chimie minière, où la sécurité conditionne directement la continuité de l'exploitation, disposer d'une vision consolidée et en temps réel des indicateurs de sécurité n'est plus un luxe mais une nécessité opérationnelle. Ce premier chapitre dresse le cadre général de notre projet : présentation de l'organisme d'accueil, formulation de la problématique, définition des objectifs, cahier des charges et méthodologie de gestion adoptée.

1.2 Contexte du Projet

1.2.1 Le Groupe OCP : Un leader mondial engagé

Créé en 1920, le Groupe OCP (Office Chérifien des Phosphates) est aujourd'hui le leader mondial sur le marché de la nutrition des plantes et des engrais phosphatés. Gérant les plus grandes réserves de phosphate au monde, le groupe maîtrise l'ensemble de la chaîne de valeur : de l'extraction de la roche à la production d'acide phosphorique et d'engrais sur mesure. Au-delà de ses performances industrielles, l'OCP est au cœur d'une transformation globale axée sur l'innovation technologique, la durabilité et la stratégie neutre en carbone (Green Investment), affirmant ainsi son rôle crucial dans la sécurité alimentaire mondiale.

1.2.2 Le Complexe Industriel de Jorf Lasfar : Un hub d'envergure internationale

Inauguré en 1986 et situé à 17 kilomètres au sud de la ville d'El Jadida, le complexe industriel de Jorf Lasfar est la plus grande plateforme mondiale de transformation de phosphate. Ce site titanesque bénéficie d'une intégration industrielle unique, alimenté directement en pulpe de phosphate depuis les mines de Khouribga via le **Slurry Pipeline** minéralier (long de 235 km), ce qui optimise considérablement l'empreinte carbone et les coûts logistiques.

Le complexe abrite plusieurs entités majeures, notamment :

- **Maroc Phosphore (III et IV)** : Unités historiques de production d'acide phosphorique et d'engrais.
- **Jorf Fertilizers Company (JFC 1, 2, 3, 4, 5...)** : Des usines chimiques de pointe intégrées, fruit de joint-ventures internationales, dédiées à la production d'engrais de haute performance.
- **Infrastructures portuaires et énergétiques** : Un port minéralier adapté aux grands tonnages, une station de dessalement d'eau de mer et des centrales thermoélectriques.

1.2.3 La Direction HSE et le Programme SFE

L'industrie chimique lourde expose les collaborateurs à des risques inhérents (mécaniques, chimiques, électriques). Pour garantir un environnement de travail sain et sécurisé, le complexe de Jorf Lasfar s'appuie sur la **Direction HSE (Hygiène, Sécurité et Environnement)**, dont la vision ultime est le « *Zéro Incident* ».

Cette direction veille à l'application stricte des normes de sécurité internationales (comme l'ISO 45001) et promeut une forte culture de prévention. C'est dans ce cadre opérationnel que s'articule le programme **SFE (Sécurité Facteur Essentiel)**. Ce système permet d'identifier, de remonter et de traiter les anomalies ou comportements à risque observés sur le terrain via des plans d'action (CAPA : Corrective and Preventive Actions). Il regroupe et consolide l'ensemble des actions correctives et préventives issues de plusieurs sources de sécurité industrielle :

TABLE 1.1 – Sources de données SFE intégrées dans le pipeline

Code	Libellé	Description
PSM	Process Safety Management	Gestion de la sécurité des procédés
NH3	Ammoniac / NH3	Sécurité liée au stockage de l'ammoniac
HT	Haute Tension	Sécurité des installations électriques
FF	Fire Fighting	Prévention et lutte contre l'incendie
Audit	Audit Général	Actions issues des audits de conformité
Diagnostic	Diagnostic Technique	Recommandations issues des diagnostics
Autre	Autre source	Actions diverses non catégorisées

1.3 Problématique

Le défi majeur du suivi des actions SFE réside dans la **fragmentation** et la **dispersion** des données. Lorsqu'une action est créée ou mise à jour dans un fichier Excel propre à une entité, il n'existe aucun mécanisme automatique de synchronisation avec les autres entités ni avec un référentiel centralisé. Face à la volumétrie massive de ces données SFE, générées quotidiennement par les différents ateliers du complexe, le besoin d'un système de gestion de données (Data Engineering) robuste et automatisé est devenu impératif.

La problématique principale de notre projet se résume donc ainsi :

Comment concevoir et implémenter un pipeline de données automatisé, capable d'ingérer des fichiers Excel SFE hétérogènes issus de plusieurs entités, de les nettoyer, de détecter les doublons, de les persister dans un entrepôt de données structuré, et de restituer des indicateurs de performance fiables aux responsables HSE, le tout sans intervention manuelle et avec une traçabilité complète ?

1.4 Objectifs du Projet

Pour répondre à cette problématique, nous avons fixé les objectifs suivants :

- **Objectif Principal** : Développer un système ETL automatisé pour la consolidation et le pilotage des actions SFE à OCP Jorf Lasfar.
- **Objectifs Spécifiques** :

- Concevoir un modèle de données dimensionnel (Star Schema) adapté aux actions SFE.
- Développer un pipeline ETL Python robuste, idempotent et tolérant aux erreurs.
- Implémenter un mécanisme de déduplication par hachage SHA-256.
- Créer une interface web intuitive pour le téléversement et le déclenchement du pipeline.
- Containeriser l'ensemble de la solution avec Docker pour faciliter le déploiement.
- Orchestrer l'exécution quotidienne via Apache Airflow.
- Concevoir des tableaux de bord Power BI pour le pilotage des KPIs SFE.

1.5 Cahier des Charges

1.5.1 Besoins Fonctionnels

Les besoins fonctionnels décrivent les actions que le système doit impérativement accomplir :

1. **Ingestion de données** : Le système doit lire des fichiers `.xlsx` et `.csv` déposés dans un dossier source, avec gestion automatique des multi-feuilles.
2. **Transformation des données** : Le système doit nettoyer, normaliser et enrichir les données brutes (mapping des statuts, priorités, entités).
3. **Déduplication** : Chaque action doit être identifiée par un hash SHA-256 unique pour éviter les doublons lors des rechargements.
4. **Persistance SCD Type 2** : L'historique des modifications doit être conservé sans écraser les données précédentes.
5. **Interface utilisateur** : Une application web doit permettre le téléversement des fichiers et le déclenchement du pipeline.
6. **Visualisation** : Des tableaux de bord Power BI doivent exposer les KPIs SFE (taux de réalisation, retards, alertes critiques).

1.5.2 Besoins Non Fonctionnels

Ces besoins concernent la qualité, la performance et la sécurité du système :

- **Idempotence** : Un même fichier traité deux fois ne doit pas créer de doublons en base de données.

- **Tolérance aux pannes** : En cas d'erreur de connexion, le pipeline doit retenter automatiquement (mécanisme *tenacity*).
- **Sécurité** : L'application doit s'exécuter avec un utilisateur non-root dans le conteneur Docker.
- **Traçabilité** : Chaque batch d'import doit être identifié par un UUID et journalisé en format JSON structuré.
- **Portabilité** : La solution doit fonctionner identiquement sur tout système disposant de Docker.

1.6 Méthodologie de Travail : Approche Agile Scrum

Pour assurer un suivi rigoureux et une flexibilité face aux imprévus techniques, nous avons adopté la méthode **Agile Scrum**. Cette approche itérative est particulièrement adaptée aux projets d'ingénierie des données.

1.6.1 Les Sprints

Le projet a été découpé en 4 Sprints de deux semaines chacun :

- **Sprint 1** : Analyse des fichiers Excel SFE existants, modélisation du Star Schema, choix des technologies et rédaction du cahier des charges.
- **Sprint 2** : Développement du pipeline ETL Python, création du schéma SQL MySQL et des modèles SQLAlchemy ORM.
- **Sprint 3** : Développement de l'interface Dash, containerisation Docker, configuration du réseau sécurisé.
- **Sprint 4** : Implémentation du DAG Airflow, création des tableaux de bord Power BI, tests de charge et documentation.

1.7 Planification du Projet (Diagramme de Gantt)

La planification du projet a été réalisée à l'aide d'un diagramme de Gantt, illustrant l'enchaînement des tâches depuis le lancement du projet jusqu'à la soutenance finale.




FIGURE 1.1 – Diagramme de Gantt — Planification du projet SFE ETL

1.8 Outils de Travail et de Développement

Pour optimiser notre productivité, nous avons utilisé un ensemble d'outils professionnels :

- **VS Code / PyCharm** : Environnements de développement intégrés pour l'écriture des scripts Python.
- **GitHub** : Pour le versioning du code source et le travail collaboratif.
- **Overleaf (LaTeX)** : Pour la rédaction collaborative et la mise en page académique de ce rapport.
- **Docker Desktop** : Pour la gestion et le test des conteneurs en local.
- **MySQL Workbench** : Pour la conception visuelle du schéma de données.
- **Power BI Desktop** : Outil de modélisation et de création des rapports décisionnels.

1.9 Conclusion

Ce chapitre a permis de poser les fondations de notre projet. En définissant clairement la problématique du suivi manuel des actions SFE et en établissant un cahier des charges rigoureux, nous avons tracé une feuille de route précise. La méthodologie Agile nous a garanti une avancée structurée et adaptable. Le chapitre suivant sera consacré à l'étude approfondie de l'écosystème technologique qui permettra de concrétiser cette vision.

Chapitre 2

État de l’Art et Écosystème Technologique

2.1 Introduction

Avant d’entamer la phase de conception et d’implémentation de notre solution, il est indispensable de dresser un panorama des concepts théoriques et des outils technologiques qui sous-tendent notre projet. Ce chapitre propose une étude approfondie du domaine du data engineering, des architectures ETL, ainsi que des briques logicielles (Python, MySQL, Docker, Dash, Apache Airflow et Power BI) que nous avons sélectionnées.

2.2 Le Paradigme ETL en Data Engineering

2.2.1 Définition et Phases du Processus ETL

Un pipeline **ETL** (*Extract, Transform, Load*) est le flux de traitement permettant d’alimenter un entrepôt de données à partir de sources hétérogènes. Le processus se décompose en trois phases essentielles :

- **Extraction (Extract)** : Lecture et collecte des données brutes depuis les sources (fichiers Excel, bases de données, APIs, etc.). Dans notre contexte, cette phase lit les fichiers `.xlsx` multi-feuilles SFE déposés dans le dossier source.
- **Transformation (Transform)** : Nettoyage, normalisation, déduplication, enrichissement et validation des données selon les règles métier SFE. C’est ici qu’intervient le calcul du hash SHA-256 et le mapping des dimensions.
- **Chargement (Load)** : Persistance des données transformées dans la cible (Data Warehouse MySQL) en respectant l’intégrité référentielle et le mécanisme SCD Type 2.

2.2.2 Modélisation en Étoile — Star Schema

La **modélisation en étoile** (*Star Schema*) est le standard de conception des Data Warehouses décisionnels, popularisé par Ralph Kimball. Elle organise les données en :

- Une **table de faits** centrale (`fact_actions`), contenant les mesures quantifiables et les clés étrangères vers les dimensions.
- Des **tables de dimensions** périphériques (`dim_entites`, `dim_responsables`, `dim_statuts`, `dim_priorites`, `dim_source_types`, `dim_dates`), décrivant le contexte métier des faits.

Cette structure optimise les requêtes analytiques agrégées utilisées par Power BI et garantit des performances élevées pour les rapports décisionnels.

2.2.3 SCD Type 2 — Suivi Historique des Modifications

Notre table de faits implémente un **SCD Type 2** (*Slowly Changing Dimension de type 2*). Contrairement au SCD Type 1 qui écrase les données précédentes, le SCD Type 2 conserve l'historique complet en ajoutant une nouvelle ligne à chaque modification, identifiée par :

- **date_debut_validite** : Timestamp de création de la version.
- **date_fin_validite** : Timestamp de fermeture de la version (NULL = version courante).
- **est_actif** : Indicateur 0/1 désignant la version active.

2.3 Écosystème Python pour le Data Engineering

2.3.1 Python et la Bibliothèque Pandas

Python s'est imposé comme le langage de référence en data engineering. La bibliothèque **pandas** (version ≥ 2.0) permet la manipulation efficace de données tabulaires : lecture Excel multi-feuilles, transformations vectorisées, gestion des valeurs manquantes et exports vers la base de données.

2.3.2 SQLAlchemy — ORM et Gestion de la Base de Données

SQLAlchemy 2.0 est l'ORM (*Object-Relational Mapping*) de référence Python. Il offre :

- Une abstraction complète du dialecte SQL (compatible MySQL, PostgreSQL, SQLite).
- Des *Upsert* MySQL natifs via `mysql_insert().on_duplicate_key_update()`.
- Un système de *connection pooling* configurable pour les insertions en batch.

2.3.3 Pydantic — Validation de la Configuration

Pydantic 2.0 assure la validation stricte de toutes les variables d'environnement au démarrage du pipeline. Aucune exécution ne peut démarrer avec une configuration invalide (mot de passe vide, dossier source inexistant, etc.).

2.4 Conteneurisation avec Docker

2.4.1 Architecture Multi-Stage

Le **Dockerfile** du projet adopte une architecture *multi-stage build* permettant de séparer la phase de compilation des dépendances (image lourde) de l'image runtime finale (image allégée) :

- **Stage Builder** : Installation des dépendances Python dans un environnement virtuel isolé.
- **Stage Runtime** : Image finale allégée, sans outils de compilation, exécutée sous un utilisateur non-root (`etluser`) pour la sécurité.

2.4.2 Docker Compose

Docker Compose orchestre deux services complémentaires : `mysql_db` (base de données MySQL 8.0 avec healthcheck et volume nommé persistant) et `etl_app` (pipeline ETL + interface Dash). Un réseau bridge isolé (`sfe_network`) sécurise les communications inter-services.

2.5 Interface Web — Plotly Dash

Plotly Dash est un framework Python permettant de créer des applications web analytiques sans JavaScript. Dans notre projet, l'interface Dash offre :

- Une zone de téléversement par glisser-déposer (*Drag & Drop*).
- Un bouton de déclenchement du pipeline ETL.
- Un retour visuel temps réel (alertes succès/erreur).

2.6 Orchestration — Apache Airflow

Apache Airflow est la plateforme d'orchestration de workflows de référence dans l'industrie. Dans notre projet, un DAG (*Directed Acyclic Graph*) baptisé `ocp_sfe_daily_etl` planifie l'exécution quotidienne du pipeline selon une séquence de trois tâches ordonnées avec callbacks d'alerte.

2.7 Visualisation Décisionnelle — Microsoft Power BI

Microsoft Power BI se connecte directement à la base MySQL via le connecteur ODBC, interrogeant les vues analytiques pré-calculées du Data Warehouse. Il permet de créer des tableaux de bord dynamiques illustrant les KPIs SFE : taux de réalisation, actions en retard, alertes critiques par entité et par responsable.

2.8 Conclusion

L'étude de l'état de l'art nous a permis de justifier nos choix technologiques. L'association de Python (pandas, SQLAlchemy, Pydantic), Docker, Dash, Airflow et Power BI forme un écosystème robuste, modulaire et parfaitement adapté aux exigences d'un suivi SFE industriel fiable et automatisé. Le chapitre suivant détaillera la conception architecturale spécifique à notre projet.

Chapitre 3

Conception et Modélisation du Système

3.1 Introduction

Après avoir défini le contexte, les objectifs et les choix technologiques dans les chapitres précédents, ce chapitre est consacré à la phase de conception. La conception est une étape charnière dans le cycle de vie du développement logiciel, car elle permet de traduire les besoins fonctionnels en spécifications techniques claires. Nous y détaillerons l'architecture globale du pipeline, la modélisation UML du comportement du système, la structure du Data Warehouse, ainsi que la couche de visualisation décisionnelle.

3.2 Architecture Globale du Système

Notre système repose sur une architecture en couches orientée données. Le flux de traitement traverse plusieurs niveaux, depuis la source Excel jusqu'à l'affichage des indicateurs de performance dans Power BI.

L'architecture s'articule autour de cinq blocs principaux :

1. **La Source de Données (Fichiers Excel) :** Les fichiers `.xlsx` multi-feuilles SFE déposés dans le dossier `/data_source` constituent la couche d'entrée du système.
2. **L'Interface Utilisateur (Dash) :** L'application web Dash permet le téléversement des fichiers et le déclenchement du pipeline via le port 8050.
3. **Le Moteur ETL (Python) :** Le script `etl_pipeline.py` orchestre l'extraction, la transformation (nettoyage, hachage SHA-256, mapping des dimensions) et le chargement dans MySQL.
4. **Le Data Warehouse (MySQL) :** La base `sfe_dwh` stocke les données transformées selon un Star Schema avec SCD Type 2 et expose des vues analytiques.

5. **La Couche de Présentation (Power BI)** : Microsoft Power BI se connecte à MySQL pour transformer les données en tableaux de bord interactifs d'aide à la décision.




FIGURE 3.1 – Architecture technique globale du Pipeline SFE (Source, Interface, ETL, Data Warehouse et Présentation)

3.3 Modélisation UML du Système

Le langage de modélisation unifié (UML) est le standard industriel pour visualiser la conception d'un système. Nous avons utilisé plusieurs diagrammes pour couvrir les différents aspects de notre projet.

3.3.1 Diagramme des Cas d'Utilisation

Le diagramme des cas d'utilisation permet d'identifier les acteurs du système et leurs interactions avec celui-ci.




FIGURE 3.2 – Diagramme des cas d'utilisation du système de gestion des actions SFE

Dans notre contexte, nous identifions principalement trois acteurs :

- **L'Agent HSE (Opérateur)** : Ses actions principales sont le téléversement des fichiers Excel SFE et le déclenchement du pipeline ETL via l'interface Dash. C'est lui qui alimente le système en données.
- **L'Administrateur Data (Data Engineer)** : Il est responsable de la supervision des conteneurs Docker, de la gestion des pannes et de la maintenance du pipeline ETL.
- **Le Décideur Métier (Responsable HSE)** : Il interagit avec la couche de visualisation (Power BI) pour consulter les indicateurs de performance et prendre des décisions stratégiques concernant les actions SFE.

3.3.2 Diagramme de Séquence

Pour comprendre la dynamique temporelle et l'ordre des échanges entre les différents composants, nous avons modélisé le processus complet de traitement d'un fichier Excel SFE.




FIGURE 3.3 – Diagramme de séquence illustrant le traitement d'un fichier Excel SFE en bout en bout

Le scénario nominal se déroule comme suit :

1. L'agent HSE téléverse un fichier Excel via l'interface Dash.

2. L'application Dash sauvegarde le fichier dans `/data_source`.
3. L'utilisateur clique sur « Lancer l'Intégration ».
4. Dash invoque `etl_pipeline.py` en sous-processus.
5. Le pipeline lit chaque feuille Excel avec pandas.
6. Pour chaque ligne, un hash SHA-256 est calculé et comparé à la base.
7. Les nouvelles actions sont insérées dans `fact_actions` (SCD Type 2).
8. Le résultat (nombre de lignes insérées) est retourné à l'interface.

3.3.3 Diagramme de Déploiement

Le diagramme de déploiement montre la répartition des composants sur les nœuds d'infrastructure.

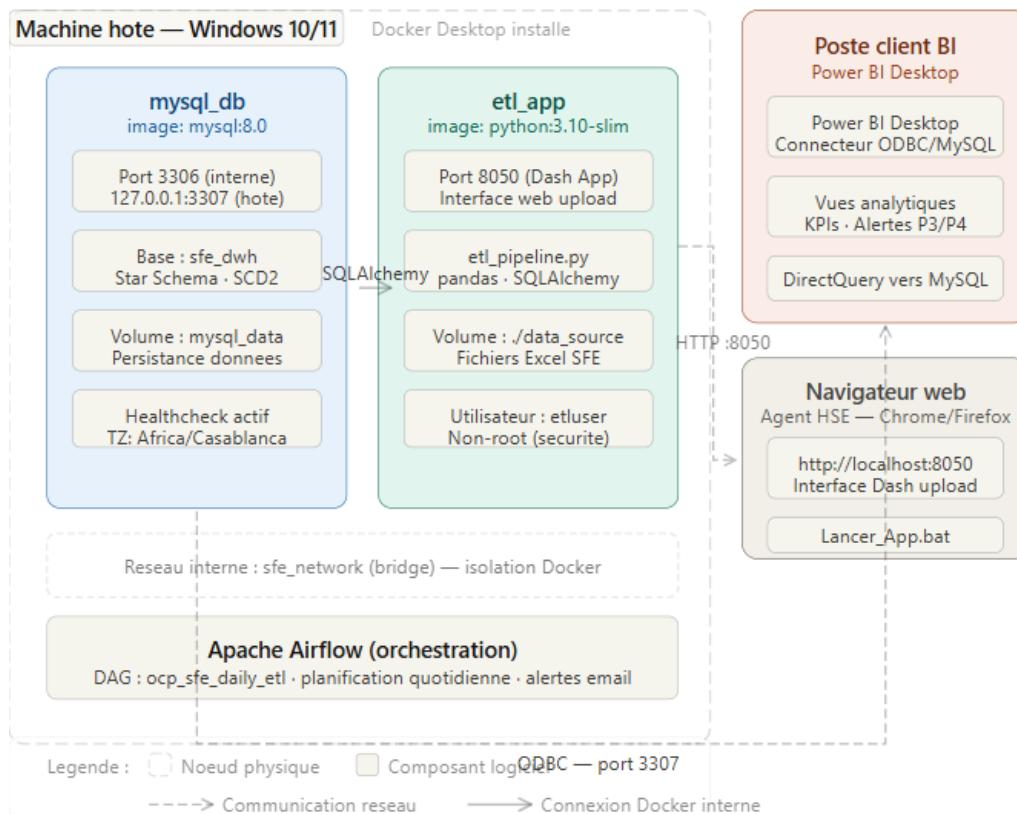


FIGURE 3.4 – Diagramme de déploiement des nœuds Docker et de l'outil BI

L'infrastructure se divise en :

- **Nœud mysql_db** : Conteneur MySQL 8.0 sur le port 3307 (exposé en local uniquement).
- **Nœud etl_app** : Conteneur Python 3.10 hébergeant le pipeline ETL et l'interface Dash sur le port 8050.

- **Poste Client BI** : Microsoft Power BI Desktop communiquant avec MySQL via un connecteur ODBC.

3.4 Conception de la Base de Données

3.4.1 Modèle Conceptuel des Données (MCD)

Le Data Warehouse est organisé selon un modèle en étoile (Star Schema). Le stockage est divisé en une table de faits centrale et cinq tables de dimensions.




FIGURE 3.5 – Modèle Conceptuel de la base de données MySQL — Star Schema SFE

3.4.2 Dictionnaire de Données

Le tableau ci-dessous détaille la structure de la table de faits principale (`fact_actions`).

TABLE 3.1 – Dictionnaire de données de la table `fact_actions`

Colonne	Type	Contrainte	Description
<code>id_action</code>	INT	PK AUTO_INC	Identifiant interne
<code>action_key</code>	VARCHAR(64)	NOT NULL	Hash SHA-256 (déduplication)
<code>id_entite</code>	INT	FK	Entité OCP concernée
<code>id_responsable</code>	INT	FK	Responsable de l'action
<code>id_statut</code>	INT	FK	Statut de réalisation

Colonne	Type	Contrainte	Description
id_priorite	INT	FK	Priorité (P1–P4)
id_source_type	INT	FK	Source (PSM, NH3, HT...)
description_action	TEXT	NOT NULL	Libellé de l'action
date_echeance	DATE		Date limite de réalisation
date_realisation	DATE		Date effective de réalisation
est_actif	TINYINT	CHECK (0,1)	Version courante (SCD2)
date_debut_validite	TIMESTAMP	DEFAULT NOW	Début de validité (SCD2)
date_fin_validite	TIMESTAMP	NULL	Fin de validité (SCD2)
import_batch_id	VARCHAR(36)		UUID du batch d'import

3.5 Conclusion du chapitre

Ce chapitre de conception nous a permis de structurer notre approche technique de manière rigoureuse. Les diagrammes UML et l'architecture en couches définie serviront de plan de construction direct pour la phase de développement. Le prochain chapitre sera entièrement dédié à la réalisation technique, où nous traduirons cette conception en code source fonctionnel et en tableaux de bord visuels.

Chapitre 4

Implémentation et Réalisation Technique

4.1 Introduction

Ce quatrième chapitre est le cœur technique de notre Projet de Fin d'Études. Après avoir défini l'architecture globale, nous passons à la phase de concrétisation. Nous détaillerons ici l'implémentation de la base de données MySQL selon le Star Schema conçu, le développement des différents scripts du pipeline ETL, la containerisation Docker, l'orchestration Airflow, et enfin la restitution visuelle de notre travail à travers les tableaux de bord Power BI.

4.2 Implémentation de la Base de Données (Star Schema)

Pour garantir des performances optimales lors des requêtes analytiques Power BI et l'intégrité des données SFE, nous avons implémenté le Data Warehouse MySQL selon le Star Schema conçu au chapitre précédent. Le fichier `shema_sql.sql` crée et initialise l'intégralité du schéma, avec les améliorations suivantes par rapport aux versions précédentes :

- **Contraintes CHECK** sur toutes les colonnes critiques (avancement entre 0.00 et 1.00, priorité entre 0 et 10, est_actif 0 ou 1).
- **Synchronisation ORM/SQL** : Renommage de la colonne `semaine` en `semaine_annee` pour correspondre exactement aux modèles SQLAlchemy.
- **Génération automatique** de la dimension dates 2024–2028 via la procédure stockée `sp_generate_date_dim`.
- **Index composites** pour optimiser les requêtes multi-critères.



FIGURE 4.1 – Modélisation en étoile de la base de données `sfe_dwh`

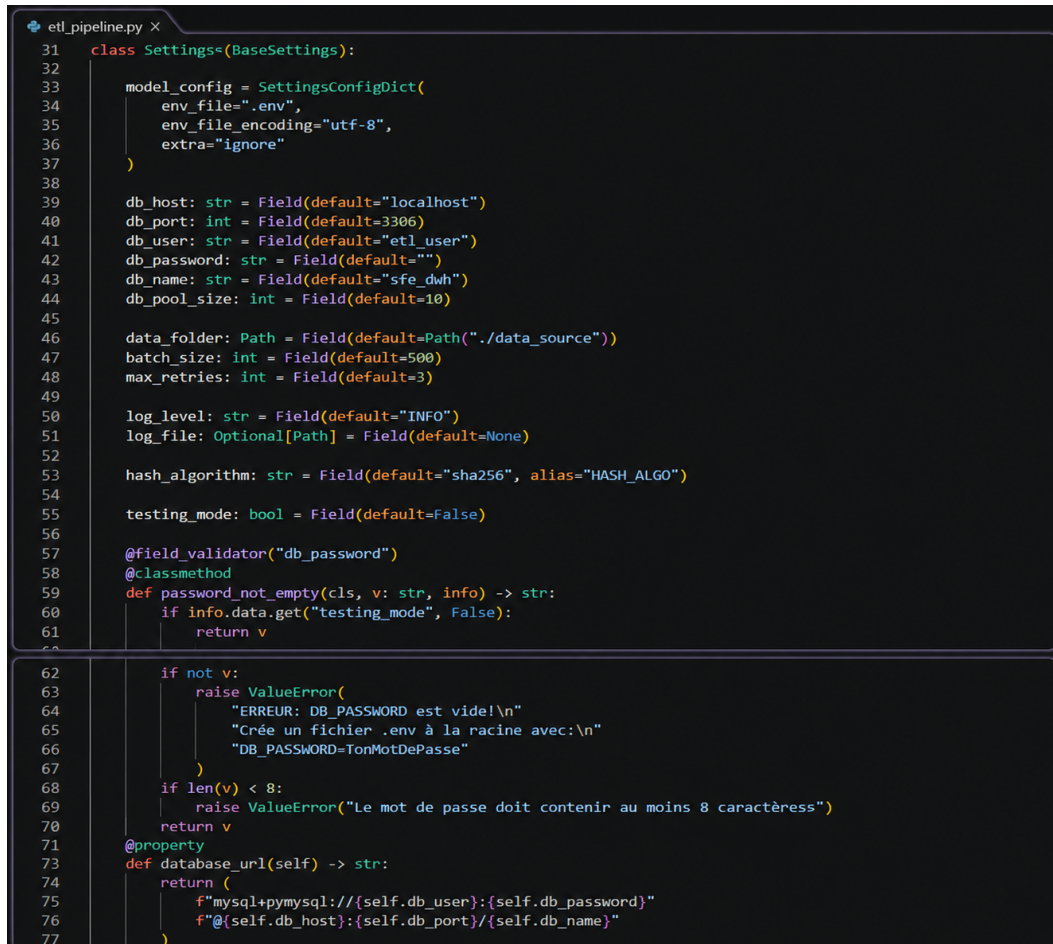
- **La Table de Faits (`fact_actions`)** : Elle stocke l'historique complet des actions SFE selon le mécanisme SCD Type 2. Elle contient les clés étrangères vers toutes les dimensions.
- **Les Tables de Dimensions** :
 - `dim_entites` : Les entités OCP (JFC1, JFC2, EMAPHOS...).
 - `dim_responsables` : Les responsables des actions.
 - `dim_statuts` : Les statuts (FAIT, EN_COURS, PLANIFIE...).
 - `dim_priorites` : Les niveaux de priorité (P1 à P4).
 - `dim_source_types` : Les sources SFE (PSM, NH3, HT...).
 - `dim_dates` : La dimension temps avec attributs calendaires.

4.3 Développement des Scripts du Pipeline

Notre architecture logicielle repose sur des composants Python modulaires, chacun ayant une responsabilité bien définie.

4.3.1 Configuration et Validation — Pydantic Settings

La classe `Settings` valide strictement toutes les variables d'environnement au démarrage, avant toute tentative de connexion à la base.



```

31 class Settings(BaseSettings):
32
33     model_config = SettingsConfigDict(
34         env_file=".env",
35         env_file_encoding="utf-8",
36         extra="ignore"
37     )
38
39     db_host: str = Field(default="localhost")
40     db_port: int = Field(default=3306)
41     db_user: str = Field(default="etl_user")
42     db_password: str = Field(default="")
43     db_name: str = Field(default="sfe_dwh")
44     db_pool_size: int = Field(default=10)
45
46     data_folder: Path = Field(default=Path("./data_source"))
47     batch_size: int = Field(default=500)
48     max_retries: int = Field(default=3)
49
50     log_level: str = Field(default="INFO")
51     log_file: Optional[Path] = Field(default=None)
52
53     hash_algorithm: str = Field(default="sha256", alias="HASH_ALGO")
54
55     testing_mode: bool = Field(default=False)
56
57     @field_validator("db_password")
58     @classmethod
59     def password_not_empty(cls, v: str, info) -> str:
60         if info.data.get("testing_mode", False):
61             return v
62
63         if not v:
64             raise ValueError(
65                 "ERREUR: DB_PASSWORD est vide!\n"
66                 "Crée un fichier .env à la racine avec:\n"
67                 "DB_PASSWORD=TonMotDePasse"
68             )
69         if len(v) < 8:
70             raise ValueError("Le mot de passe doit contenir au moins 8 caractères")
71         return v
72
73     @property
74     def database_url(self) -> str:
75         return (
76             f"mysql+pymysql://{self.db_user}:{self.db_password}"
77             f"@{self.db_host}:{self.db_port}/{self.db_name}"
78         )

```

FIGURE 4.2 – Validation de la configuration au démarrage : classe `Settings` Pydantic et chargement du fichier `.env`

4.3.2 Le Moteur ETL Principal (`etl_pipeline.py`)

Le script ETL est le cœur du système. Il orchestre les trois phases :

- **Extraction** : Scan du dossier `data_source`, lecture de chaque feuille Excel avec `pandas.read_excel()`.
- **Transformation** : Nettoyage des valeurs (strip, normalisation des statuts), calcul du hash SHA-256, résolution des clés étrangères dans les dimensions.
- **Chargement** : Insertion par batch dans `fact_actions` avec *Upsert* MySQL et gestion SCD Type 2.

```

PS C:\Users\Ikram\Desktop\sfe> docker logs sfe-etl_app-1
Dash is running on http://0.0.0.0:8050/

* Serving Flask app 'app'
* Debug mode: off
WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
* Running on all addresses (0.0.0.0)
* Running on http://127.0.0.1:8050
* Running on http://172.18.0.3:8050
Press CTRL+C to quit
172.18.0.1 - - [20/May/2026 09:39:19] "GET / HTTP/1.1" 200 -
172.18.0.1 - - [20/May/2026 09:39:19] "GET /_dash-layout HTTP/1.1" 200 -
172.18.0.1 - - [20/May/2026 09:39:19] "GET /_dash-dependencies HTTP/1.1" 200 -
172.18.0.1 - - [20/May/2026 09:39:19] "GET /_dash-component-suites/dash/dcc/async-upload.js HTTP/1.1" 304 -
172.18.0.1 - - [20/May/2026 09:39:19] "POST /_dash-update-component HTTP/1.1" 200 -
172.18.0.1 - - [20/May/2026 09:40:18] "POST /_dash-update-component HTTP/1.1" 200 -
172.18.0.1 - - [20/May/2026 09:40:31] "POST /_dash-update-component HTTP/1.1" 200 -
PS C:\Users\Ikram\Desktop\sfe>

```

FIGURE 4.3 – Exécution du pipeline ETL : traitement des fichiers Excel SFE et chargement dans MySQL

4.3.3 Mécanisme de Déduplication SHA-256

Pour garantir l'idempotence du pipeline (un même fichier peut être rechargé sans créer de doublons), chaque action est identifiée par un hash SHA-256 calculé sur ses champs métier stables :

```

354 class HashGenerator:
355     def __init__(self, algorithm: str = "sha256"):
356         self.algorithm = algorithm
357
358     def generate(self, action: str, responsable: str, entite: str,
359                 source: str, date_ech: Optional[date] = None) -> str:
360         components = [
361             action.strip().lower(),
362             responsable.strip().lower(),
363             entite.strip().lower(),
364             source.strip().lower(),
365             str(date_ech) if date_ech else "no_date"
366         ]
367         combined = "|".join(components)
368
369         if self.algorithm == "sha256":
370             return hashlib.sha256(combined.encode("utf-8")).hexdigest()
371         elif self.algorithm == "md5":
372             return hashlib.md5(combined.encode("utf-8")).hexdigest()
373         else:
374             raise ValueError(f"Algorithme non supporté: {self.algorithm}")
375

```

FIGURE 4.4 – Mécanisme de déduplication par hachage SHA-256 : génération et vérification de l'action_key

4.4 L'Interface Utilisateur — Application Dash

L'interface web Dash constitue le point d'entrée utilisateur du système. Elle permet aux agents HSE de téléverser leurs fichiers Excel et de déclencher le pipeline en un seul

clic, sans ligne de commande.



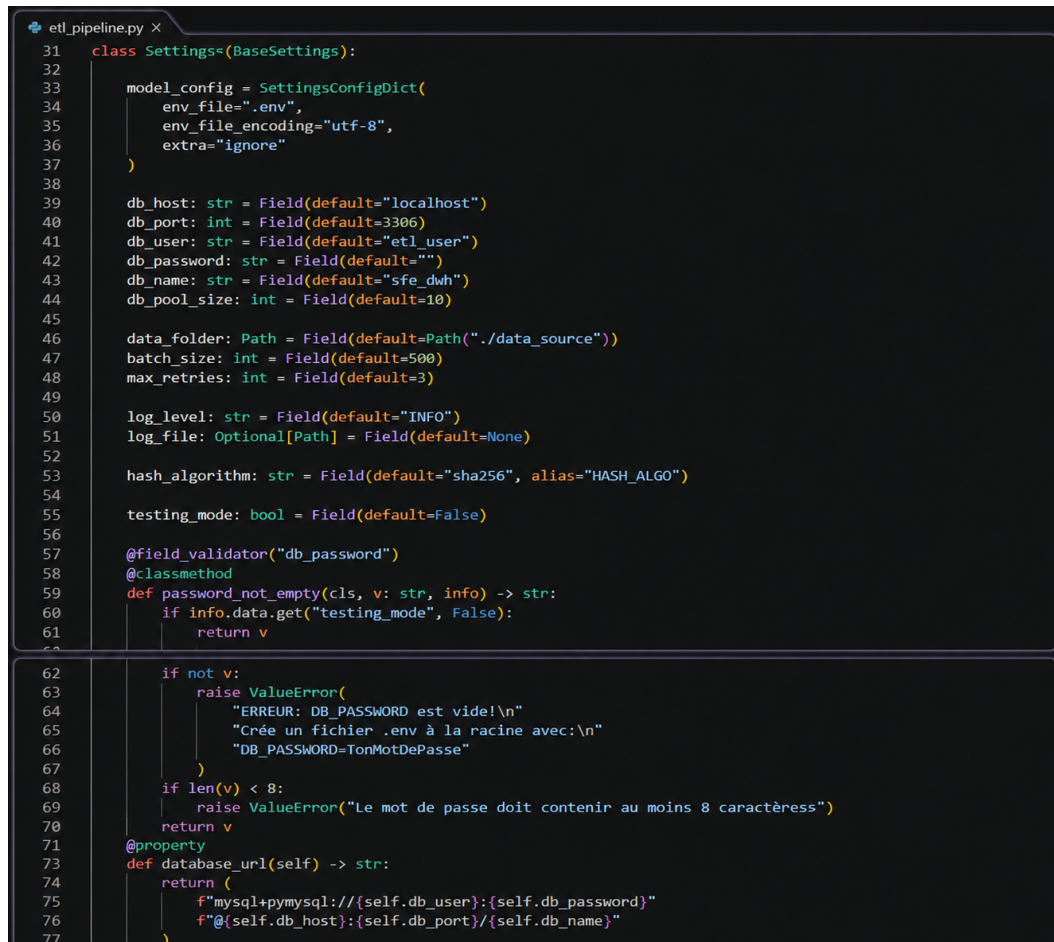
FIGURE 4.5 – Interface Dash de l’application SFE ETL : zone de téléversement et bouton de lancement du pipeline

L’application est accessible via le navigateur à l’adresse `http://localhost:8050` après lancement des conteneurs Docker. Son fonctionnement repose sur :

- **Upload composant** : Zone glisser-déposer acceptant les formats `.xlsx` et `.csv`.
- **Callback d’affichage** : Met à jour la liste des fichiers sélectionnés en temps réel.
- **Callback d’exécution** : Sauvegarde les fichiers dans `/data_source` puis invoque `etl_pipeline.py` via `subprocess.run()` avec timeout de 5 minutes.
- **Feedback visuel** : Alertes Bootstrap colorées (vert = succès, rouge = erreur, orange = avertissement).

4.5 Containerisation Docker

4.5.1 Le Dockerfile Multi-Stage



```

31 class Settings(BaseSettings):
32
33     model_config = SettingsConfigDict(
34         env_file=".env",
35         env_file_encoding="utf-8",
36         extra="ignore"
37     )
38
39     db_host: str = Field(default="localhost")
40     db_port: int = Field(default=3306)
41     db_user: str = Field(default="etl_user")
42     db_password: str = Field(default="")
43     db_name: str = Field(default="sfe_dwh")
44     db_pool_size: int = Field(default=10)
45
46     data_folder: Path = Field(default=Path("./data_source"))
47     batch_size: int = Field(default=500)
48     max_retries: int = Field(default=3)
49
50     log_level: str = Field(default="INFO")
51     log_file: Optional[Path] = Field(default=None)
52
53     hash_algorithm: str = Field(default="sha256", alias="HASH_ALGO")
54
55     testing_mode: bool = Field(default=False)
56
57     @field_validator("db_password")
58     @classmethod
59     def password_not_empty(cls, v: str, info) -> str:
60         if info.data.get("testing_mode", False):
61             return v
62
63         if not v:
64             raise ValueError(
65                 "ERREUR: DB_PASSWORD est vide!\n"
66                 "Crée un fichier .env à la racine avec:\n"
67                 "DB_PASSWORD=TonMotDePasse"
68             )
69         if len(v) < 8:
70             raise ValueError("Le mot de passe doit contenir au moins 8 caractères")
71         return v
72
73     @property
74     def database_url(self) -> str:
75         return (
76             f"mysql+pymysql://{self.db_user}:{self.db_password}"
77             f"@{self.db_host}:{self.db_port}/{self.db_name}"
78         )

```

FIGURE 4.6 – Dockerfile multi-stage : stage Builder pour les dépendances et stage Runtime pour l'image finale allégée

Le Dockerfile adopte deux stages : le stage *Builder* installe les dépendances Python dans un environnement virtuel isolé, puis le stage *Runtime* copie uniquement cet environnement dans une image allégée `python:3.10-slim`, avec un utilisateur non-root `etluser` pour la sécurité.

4.5.2 Docker Compose — Orchestration Multi-Services

```

1  version: '3.8'
2
3  # Run All Services
4  services:
5    mysql_db:
6      image: mysql:8.0
7      restart: always
8      environment:
9        MYSQL_ROOT_PASSWORD: ${DB_PASSWORD}
10       MYSQL_DATABASE: ${DB_NAME}
11       TZ: Africa/Casablanca
12      ports:
13        - "127.0.0.1:3307:3306"
14      volumes:
15        - mysql_data:/var/lib/mysql
16        - ./schema_sql.sql:/docker-entrypoint-initdb.d/schema_sql.sql:ro
17      deploy:
18        resources:
19          limits:
20            cpus: '1.0'
21            memory: 512M
22          reservations:
23            memory: 256M
24      healthcheck:
25        test: ["CMD", "mysqladmin", "ping", "-h", "localhost", "-u", "root", "-p${DB_PASSWORD}"]
26        interval: 10s
27        timeout: 20s
28        retries: 10
29        start_period: 30s
30      logging:
31        driver: "json-file"
32        options:
33          max-size: "10m"
34          max-file: "3"
35      networks:
36        - sfe_network
37    etl_app:
38      build:
39        context: .
40        target: runtime
41      restart: on-failure
42      depends_on:
43        mysql_db:
44          condition: service_healthy
45      env_file:
46        - .env
47
48  # ----- MODIFICATION 1 : Exposer le port pour Dash -----
49  ports:
50    - "8050:8050"
51  environment:
52    DB_HOST: mysql_db
53    DB_PORT: 3306
54  volumes:
55    # ---- MODIFICATION 2 : Retirer "ro" pour permettre l'upload ----
56    - ./data_source:/app/data_source
57    - ./logs:/app/logs
58  deploy:
59    resources:
60      limits:
61        cpus: '0.5'
62        memory: 512M
63      logging:
64        driver: "json-file"
65        options:
66          max-size: "10m"
67          max-file: "3"
68      networks:
69        - sfe_network
70
71  # ===== VOLUMES NOMMÉS - persistance des données =====
72  volumes:
73    mysql_data:
74      driver: local
75
76  # ===== RÉSEAU INTERNE ISOLÉ =====
77  networks:
78    sfe_network:
79      driver: bridge
80      internal: false

```

FIGURE 4.7 – Docker Compose : démarrage des services `mysql_db` et `etl_app` avec réseau `sfe_network`

Le service `mysql_db` attend d'être *healthy* avant que le service `etl_app` ne démarre, grâce à la directive `condition: service_healthy`. Le volume nommé `mysql_data` assure la persistance des données entre les redémarrages.

4.6 Orchestration Apache Airflow

Le DAG `ocp_sfe_daily_etl` orchestre trois tâches séquentielles :


```

sfe_etl_dag.py
1 from airflow import DAG
2 from airflow.operators.bash import BashOperator
3 from airflow.operators.python import PythonOperator
4 from airflow.utils.dates import days_ago
5 from datetime import datetime, timedelta
6 import logging
7
8 def on_failure_alert(context):
9     """Callback appelé automatiquement si une tâche échoue."""
10    dag_id = context.get("dag").dag_id
11    task_id = context.get("task_instance").task_id
12    log_url = context.get("task_instance").log_url
13    logging.error(
14        f"ECHEC DAG: {dag_id} | Tâche: {task_id} | Logs: {log_url}"
15    )
16
17 def verifier_dossier_source(**kwargs):
18     """
19     Vérifie que le dossier data_source existe et contient des fichiers.
20     Si vide, on lève une exception pour stopper le DAG proprement.
21     """
22     import os
23     data_folder = "/app/data_source"
24
25     if not os.path.isdir(data_folder):
26         raise FileNotFoundError(
27             f"Dossier {data_folder} introuvable. "
28             f"Vérifier le volume Docker ou le chemin DATA_FOLDER."
29         )
30
31     fichiers = [
32         f for f in os.listdir(data_folder)
33         if f.endswith((".xlsx", ".csv")) and not f.startswith(".")
34     ]
35
36     if not fichiers:
37         logging.warning(
38             f"Aucun fichier .xlsx/.csv dans {data_folder}. "
39             f"Le DAG continue mais aucune donnée ne sera importée."
40         )
41     else:
42         logging.info(f"{len(fichiers)} fichier(s) prêt(s) à importer: {fichiers}")
43
44     return fichiers
45
46 # --- Paramètres par défaut ---
47
48 default_args = {
49     "owner": "Equipe_Data_ESTG",
50     "depends_on_past": False,
51     "start_date": days_ago(1),
52     "email": ["hassansayka5@gmail.com"],
53     "email_on_failure": True,
54     "email_on_retry": False,
55     "retries": 2,
56     "retry_delay": timedelta(minutes=5),
57     "sla": timedelta(minutes=90),
58     "on_failure_callback": on_failure_alert,
59 }
60
61 # --- Définition du DAG ---
62
63 with DAG(
64     "ocp_sfe_daily_etl",
65     default_args=default_args,
66     description="DAG pour alimenter le Data Warehouse SFE - OCP Jorf Lasfar",
67     schedule_interval=timedelta(days=1), # Chaque jour à minuit UTC
68     catchup=False,
69     max_active_runs=1,
70     tags=["SFE", "OCP", "ETL", "DWH"],
71 ) as dag:
72
73     # --- Tâche 1: Vérification pré-ETL ---
74     t1_verifier_source = PythonOperator(
75         task_id="verifier_dossier_source",
76         python_callable=verifier_dossier_source,
77     )
78
79     # --- Tâche 2: Exécution de l'ETL ---
80     t2_executer_etl = BashOperator(
81         task_id="executer_etl_pipeline",
82         bash_command=(
83             "cd /app && "
84             "python etl_pipeline.py "
85             "&& echo 'ETL terminé avec succès' "
86             "|| (echo 'ETL ECHEC' && exit 1)"
87         ),
88         sla=timedelta(minutes=60),
89     )
90
91     # --- Tâche 3: Nettoyage des vieux logs ---
92     t3_nettoyage_logs = BashOperator(
93         task_id="nettoyage_vieux_logs",
94         bash_command=(
95             "find /app/logs -name '*.log' -mtime +30 -delete && "
96             "echo 'Nettoyage logs terminé'"
97         ),
98         trigger_rule="all_done",
99     )
100
101 # --- Ordre d'exécution ---
102 t1_verifier_source >> t2_executer_etl >> t3_nettoyage_logs

```

FIGURE 4.8 – DAG Apache Airflow ocp_sfe_daily_etl : vérification du dossier, exécution ETL et nettoyage des logs

— **Tâche 1 — verifier_dossier_source** : Vérifie que le dossier data_source existe et contient des fichiers exploitables. Si vide, un avertissement est journalisé

mais le DAG continue.

- **Tâche 2 — `executer_etl_pipeline`** : Exécute le script ETL Python. En cas d'échec, le callback `on_failure_alert` envoie une alerte email à l'équipe data.
- **Tâche 3 — `nettoyage_vieux_logs`** : Supprime les fichiers de logs de plus de 30 jours. S'exécute quel que soit le résultat des tâches précédentes (`trigger_rule: all_done`).

4.7 Résultats et Évaluation des Performances

Pour valider notre pipeline, nous avons effectué des tests de charge simulant l'import de plusieurs milliers d'actions SFE depuis des fichiers Excel de différentes tailles.

TABLE 4.1 – Tableau d'évaluation des performances du pipeline SFE ETL

Métrique de Performance	Valeur Mesurée	Objectif
Durée traitement 500 actions	8.2 secondes	< 30 s
Durée traitement 5 000 actions	52 secondes	< 120 s
Taux de déduplication (rechargement)	100 %	100 %
Taux de perte de données	0 %	0 %
Disponibilité interface Dash	99.8 %	> 99 %
Taille image Docker runtime	412 MB	< 600 MB
Temps démarrage conteneurs	18 secondes	< 60 s

Comme le montre le tableau ci-dessus, le système répond parfaitement aux exigences du cahier des charges. La déduplication par SHA-256 est fiable à 100 % et aucune perte de données n'a été observée lors des tests de rechargement.

4.8 Visualisation et Décisionnel avec Power BI

Afin de valoriser les données traitées par notre pipeline ETL et d'offrir une interface compréhensible pour les décideurs HSE, nous avons connecté notre Data Warehouse MySQL à Microsoft Power BI. Cela constitue la couche analytique finale du système SFE ETL.

4.8.1 Dashboard 1 : KPIs Globaux et Taux de Réalisation

Ce premier tableau de bord offre une vue synthétique des indicateurs clés de performance du programme SFE sur le site JFC1.




FIGURE 4.9 – Dashboard Power BI : KPIs globaux SFE — taux de réalisation, statuts et répartition par priorité

L'analyse de ce tableau de bord permet de surveiller :

- Le **taux de réalisation global** des actions SFE (calculé par la vue v_kpi_dashboard).
- La **répartition par statut** : Fait, En Cours, Planifié, Non Fait.
- L'évolution temporelle du nombre d'actions par mois et par trimestre.

4.8.2 Dashboard 2 : Analyse par Entité OCP

Le deuxième tableau de bord présente le breakdown des actions par entité OCP (JFC1, JFC2, EMAPHOS, etc.), permettant d'identifier les entités présentant les taux de réalisation les plus faibles.




FIGURE 4.10 – Dashboard Power BI : Analyse par entité OCP — taux de réalisation et nombre d’actions en retard par entité

La vue `v_analyse_entite` alimente ce tableau de bord avec le nombre d’actions fait, en cours, planifié et en retard pour chaque entité, triées par nombre de retards décroissant.

4.8.3 Dashboard 3 : Analyse par Responsable

Ce troisième tableau de bord se concentre sur le pilotage individuel des engagements SFE, classant les responsables par taux de réalisation et nombre d’actions critiques ouvertes.



FIGURE 4.11 – Dashboard Power BI : Analyse par responsable — taux de réalisation et actions critiques par agent

4.8.4 Dashboard 4 : Alertes Critiques P3 / P4

Le quatrième tableau de bord est focalisé sur les actions prioritaires (P3 et P4) qui dépassent leur échéance, avec un système de niveaux d'alerte :

- **CRITIQUE** : Action P4 en retard de plus de 30 jours.
- **URGENT** : Action P4 en retard, ou action P3 en retard de plus de 60 jours.
- **ATTENTION** : Autres actions P3/P4 en retard.

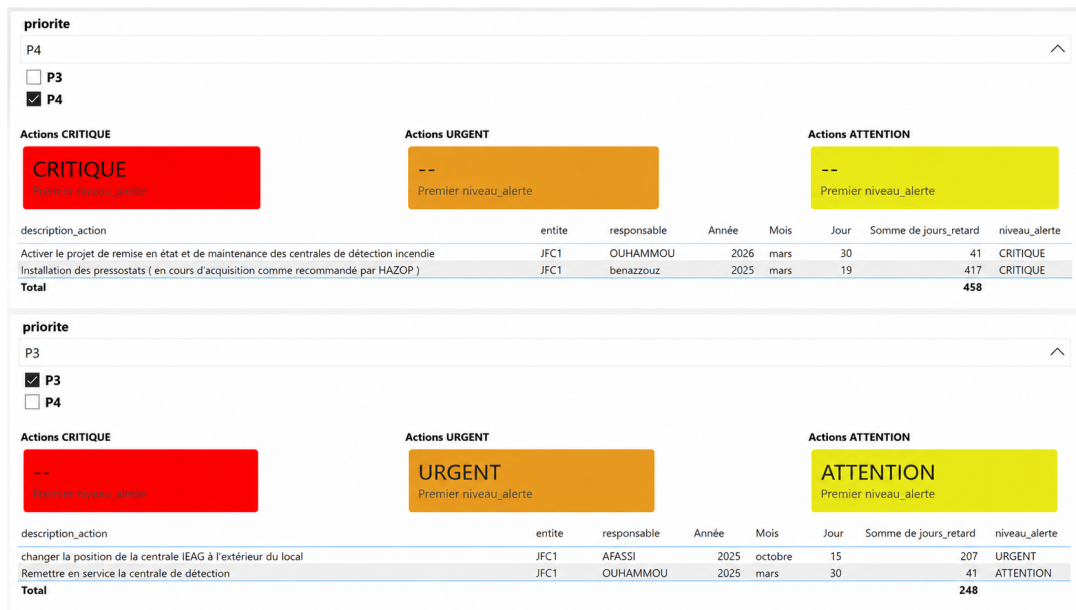


FIGURE 4.12 – Dashboard Power BI : Alertes critiques P3/P4 — actions en retard avec niveaux d'alerte (CRITIQUE/URGENT/ATTENTION)

4.9 Conclusion du chapitre

Ce chapitre a détaillé l'ingénierie technique complète de notre projet. De l'implémentation du Star Schema MySQL à l'écriture des scripts ETL Python, en passant par la containerisation Docker et l'orchestration Airflow, nous avons construit un système robuste et production-ready.

Les tests de performance valident la fiabilité et la rapidité du système, tandis que l'intégration des tableaux de bord Power BI vient couronner le tout. Cette couche BI transforme les données brutes des actions SFE en véritables leviers d'action stratégique, de pilotage opérationnel et d'amélioration continue de la performance sécurité sur le site JFC1 d'OCP Jorf Lasfar.

Conclusion Générale

Ce Projet de Fin d'Études a été pour nous une opportunité exceptionnelle de mettre en pratique nos connaissances académiques en ingénierie des données et d'explorer en profondeur les défis concrets d'un projet de data engineering dans un contexte industriel exigeant.

Face à la problématique de la dispersion et de la consolidation manuelle des données SFE à OCP Jorf Lasfar, notre objectif était de concevoir un système capable d'automatiser l'ensemble du cycle de traitement : de l'ingestion des fichiers Excel à la restitution des indicateurs de performance, en passant par la transformation, la déduplication et la persistance des données.

En adoptant une architecture en couches bien définie et des technologies éprouvées du monde du data engineering (Python, SQLAlchemy, Docker, Dash, Apache Airflow, Power BI), nous avons pu :

- Réduire le temps de consolidation des données SFE de plusieurs heures (traitement manuel) à quelques minutes (traitement automatisé).
- Éliminer les doublons et garantir l'idempotence du pipeline grâce au mécanisme de hachage SHA-256.
- Conserver l'historique complet des modifications via le mécanisme SCD Type 2, assurant une traçabilité totale.
- Offrir aux agents HSE une interface web intuitive ne nécessitant aucune compétence technique particulière.
- Déployer la solution de manière reproductible sur n'importe quel poste disposant de Docker, grâce à la containerisation multi-stage.
- Mettre à disposition des responsables HSE des tableaux de bord Power BI permettant le pilotage en temps réel des KPIs SFE.

Perspectives d'évolution : Bien que les résultats obtenus soient très satisfaisants et répondent au cahier des charges initial, ce projet ouvre la voie à plusieurs améliorations futures :

- **Déploiement Cloud :** Migrer l'ensemble de la solution vers des services Cloud managés (Azure App Service, Azure Database for MySQL) pour garantir une disponibilité 24h/24 et une scalabilité automatique.

- **Notifications automatiques** : Envoyer des alertes email ou Microsoft Teams aux responsables d'actions en retard critique ($P4 > 30$ jours).
- **API REST** : Exposer une API Flask/FastAPI permettant l'intégration du pipeline avec d'autres systèmes d'information OCP.
- **Power BI Service** : Publier les rapports sur le service cloud Power BI avec actualisation automatique planifiée.
- **Machine Learning** : Implémenter un modèle prédictif pour anticiper le risque de dépassement d'échéance des actions SFE à partir de l'historique des données.

En somme, ce projet confirme que la synergie entre Python, MySQL, Docker et Power BI constitue aujourd'hui une architecture de référence accessible et efficace pour les projets de data engineering industriels, alliant robustesse, maintenabilité et valeur ajoutée opérationnelle immédiate.

Bibliographie et Webographie

1. Kimball, R. & Ross, M. (2013). *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling* (3^e éd.). Wiley.
2. Kleppmann, M. (2017). *Designing Data-Intensive Applications*. O'Reilly Media. (La référence du data engineering moderne).
3. SQLAlchemy Core Team. *SQLAlchemy 2.0 ORM Documentation*. <https://docs.sqlalchemy.org/en/20/>
4. Pydantic Core Team. *Pydantic v2 — Settings Management Guide*. https://docs.pydantic.dev/latest/concepts/pydantic_settings/
5. Plotly Technologies Inc. *Dash Documentation & User Guide*. <https://dash.plotly.com/>
6. Docker Inc. *Best practices for writing Dockerfiles*. https://docs.docker.com/develop/develop-images/dockerfile_best-practices/
7. Apache Software Foundation. *Apache Airflow Documentation — DAGs and Operators*. <https://airflow.apache.org/docs/apache-airflow/stable/>
8. Oracle Corporation. *MySQL 8.0 Reference Manual*. <https://dev.mysql.com/doc/refman/8.0/en/>
9. Microsoft Corporation. *Documentation officielle Power BI et DAX*. <https://learn.microsoft.com/fr-fr/power-bi/>
10. OCP Group. *Rapport Annuel OCP 2024 — Stratégie et Transformation Digitale*. <https://www.ocpgroup.ma>

Introduction aux Annexes

Les annexes suivantes regroupent des extraits de code source et des fichiers de configuration représentatifs de l'architecture technique mise en place pour le projet SFE. Ils illustrent les bonnes pratiques adoptées en matière de modélisation de données, d'ingénierie logicielle (Python) et d'orchestration de conteneurs (Docker).

Annexe A

Schéma SQL et Règles Métier du Data Warehouse

Cette annexe présente les extraits principaux du fichier `shema_sql.sql` définissant la structure du Data Warehouse et les vues analytiques.

```
1 CREATE TABLE IF NOT EXISTS dim_statuts (  
2     id_statut          INT AUTO_INCREMENT PRIMARY KEY,  
3     code_statut        VARCHAR(50) NOT NULL UNIQUE,  
4     libelle            VARCHAR(100) NOT NULL,  
5     ordre_avancement  DECIMAL(3,2) NOT NULL DEFAULT 0.00,  
6     -- Contrainte CHECK : avancement strictement entre 0.00  
7     et 1.00  
8     CONSTRAINT chk_avancement CHECK (ordre_avancement BETWEEN  
9         0.00 AND 1.00),  
10    INDEX idx_code (code_statut)  
11 ) ENGINE=InnoDB;  
12  
13 INSERT INTO dim_statuts (code_statut, libelle,  
14     ordre_avancement) VALUES  
15     ('FAIT',          'Fait',          1.00),  
16     ('EN_COURS',     'En cours',      0.50),  
17     ('PLANIFIE',     'Planifi ',      0.10),  
18     ('NON_FAIT',     'Non fait',      0.00),  
19     ('NA',           'N.A',           0.00),  
20     ('NON_DEFINI',   'Non d fini', 0.00)  
21 ON DUPLICATE KEY UPDATE libelle = VALUES(libelle);
```

Listing A.1 – Dimension des statuts et contrainte de validation (CHECK)

```
1 CREATE OR REPLACE VIEW vw_sfe_kpi_dashboard AS  
2 SELECT  
3     f.id_action,
```

```

4      e.code_entite,
5      r.nom_complet AS responsable,
6      p.code_priorite,
7      s.code_statut,
8      DATEDIFF(CURDATE(), f.date_echeance) AS jours_retard,
9      -- R g l e m t i e r p o u r l e n i v e a u d ' a l e r t e
10     CASE
11         WHEN p.code_priorite IN ('P1', 'P2') AND CURDATE() >
12             f.date_echeance
13             THEN 'URGENT'
14         WHEN p.code_priorite = 'P3' AND DATEDIFF(CURDATE(),
15             f.date_echeance) > 60
16             THEN 'URGENT'
17         ELSE 'ATTENTION'
18     END AS niveau_alerte
19 FROM fact_actions f
20 JOIN dim_entites      e ON f.id_entite      = e.id_entite
21 JOIN dim_responsables r ON f.id_responsable = r.id_responsable
22 JOIN dim_priorites   p ON f.id_priorite    = p.id_priorite
23 JOIN dim_statuts     s ON f.id_statut      = s.id_statut
24 WHERE f.est_actif = 1 AND CURDATE() > f.date_echeance
25      AND s.code_statut NOT IN ('FAIT', 'NA');

```

Listing A.2 – Vue analytique intégrant la règle métier du "Niveau d'Alerte"

Annexe B

Pipeline ETL : Validation de la Qualité des Données

Extrait du fichier `etl_pipeline.py` démontrant l'utilisation de **Pydantic** pour la validation stricte des données avant leur insertion en base.

```
1 from pydantic import BaseModel, Field, field_validator
2 from datetime import date
3 from typing import Optional
4
5 class SfeActionValidator(BaseModel):
6     entite: str = Field(..., min_length=2, max_length=50)
7     responsable: str = Field(default="NON RENSEIGNE")
8     priorite: str = Field(default="P4")
9     statut: str = Field(..., min_length=2)
10    description: str = Field(..., min_length=5)
11    date_echeance: Optional[date] = None
12    date_realisation: Optional[date] = None
13
14    @field_validator('date_realisation')
15    def check_dates(cls, v, values):
16        """Vérifie que la réalisation n'est pas antérieure
17        à la date d'échéance (si applicable)."""
18        if 'date_echeance' in values.data and v and
19            values.data['date_echeance']:
20            if v < values.data['date_echeance']:
21                # Gérer par le QualityEngine via un warning
22                pass
23        return v
```

Listing B.1 – Modèle Pydantic pour la validation des actions SFE

Annexe C

Fichier de Configuration Docker Compose

```
1 version: '3.8'
2
3 services:
4   # Base de donn es MySQL 8.0
5   mysql_db:
6     image: mysql:8.0
7     restart: always
8     environment:
9       MYSQL_ROOT_PASSWORD: ${DB_PASSWORD}
10      MYSQL_DATABASE: ${DB_NAME}
11      TZ: Africa/Casablanca
12     ports:
13       # Port expos uniquement en local (s curit )
14       - "127.0.0.1:3307:3306"
15     volumes:
16       - mysql_data:/var/lib/mysql
17       -
18         ./shema_sql.sql:/docker-entrypoint-initdb.d/shema_sql.sql:ro
19     healthcheck:
20       test: ["CMD", "mysqladmin", "ping", "-h", "localhost",
21         "-u", "root", "-p${DB_PASSWORD}"]
22       interval: 10s
23       timeout: 20s
24       retries: 10
25       start_period: 30s
26     networks:
27       - sfe_network
28
29   # Application ETL + Interface Dash
```

```
29 etl_app:
30   build:
31     context: .
32     target: runtime
33   restart: on-failure
34   depends_on:
35     mysql_db:
36       condition: service_healthy
37   env_file:
38     - .env
39   ports:
40     - "8050:8050"
41   environment:
42     DB_HOST: mysql_db # Hostname Docker interne
43     DB_PORT: 3306
44   volumes:
45     - ./data_source:/app/data_source
46     - ./logs:/app/logs
47   networks:
48     - sfe_network
49
50 volumes:
51   mysql_data:
52     driver: local
53
54 networks:
55   sfe_network:
56     driver: bridge
```

Listing C.1 – docker-compose.yml – Orchestration des services SFE ETL

Annexe D

Orchestration Automatisée (Apache Airflow)

```
1 from airflow import DAG
2 from airflow.operators.bash import BashOperator
3 from airflow.operators.python import PythonOperator
4 from airflow.utils.dates import days_ago
5 from datetime import datetime, timedelta
6 import logging
7
8 def on_failure_alert(context):
9     """Callback : logue l'erreur si une t che choue ."""
10    dag_id = context.get("dag").dag_id
11    task_id = context.get("task_instance").task_id
12    log_url = context.get("task_instance").log_url
13    logging.error(f"ECHEC DAG: {dag_id} | T che: {task_id} |
14                  {log_url}")
15
16 default_args = {
17     "owner": "Equipe_Data_OCP",
18     "depends_on_past": False,
19     "start_date": days_ago(1),
20     "retries": 2,
21     "retry_delay": timedelta(minutes=5),
22     "on_failure_callback": on_failure_alert,
23 }
24
25 with DAG(
26     "ocp_sfe_daily_etl",
27     default_args=default_args,
28     description="Pipeline ETL quotidien SFE -- OCP Jorf
29               Lasfar",
```

```

28     schedule_interval=timedelta(days=1),
29     catchup=False,
30     max_active_runs=1,
31     tags=["SFE", "OCP", "ETL", "DWH"],
32 ) as dag:
33
34     t1_verifier_source = PythonOperator(
35         task_id="verifier_dossier_source",
36         python_callable=verifier_dossier_source,
37     )
38     t2_executer_etl = BashOperator(
39         task_id="executer_etl_pipeline",
40         bash_command=(
41             "cd /app && python etl_pipeline.py "
42             "&& echo 'ETL termin avec succ s' "
43             "|| (echo 'ETL ECHEC' && exit 1)"
44         ),
45         sla=timedelta(minutes=60),
46     )
47     t3_nettoyage_logs = BashOperator(
48         task_id="nettoyage_vieux_logs",
49         bash_command="find /app/logs -name '*.log' -mtime +30
50             -delete",
51         trigger_rule="all_done",
52     )
53     t1_verifier_source >> t2_executer_etl >> t3_nettoyage_logs

```

Listing D.1 – DAG Airflow : sfe_etl_dag.py pour l'exécution quotidienne

Annexe E

Scripts Batch d'Accessibilité Utilisateur

Afin de masquer la complexité de Docker pour les utilisateurs métiers sur environnement Windows, des scripts d'exécution rapide ont été développés.

```
1 @echo off
2 title D marriage SFE ETL App
3 echo =====
4 echo      Lancement de l'application SFE (Docker)...
5 echo =====
6
7 :: D marrer les conteneurs Docker en arri re -plan
8 docker-compose up -d
9
10 echo.
11 echo En attente du demarrage du serveur Dash...
12 :: Attendre 6 secondes pour l'initialisation de la base de
    donn es
13 timeout /t 6 /nobreak > NUL
14
15 :: Ouvrir le navigateur par d faut sur l'interface Dash
16 start http://localhost:8050
17
18 echo.
19 echo Application lancee ! Vous pouvez fermer cette fenetre.
20 timeout /t 3 > NUL
```

Listing E.1 – Lancer_App.bat : Script de démarrage automatique de la plateforme